

QUANTIFICATION DES PERFORMANCES ET DE LA VALEUR
AJOUTÉE DES EXPÉRIENCES DE RÉDUCTION D'ÉCHELLE
CLIMATIQUE RÉGIONALE SUR LA RÉGION DE L'ASIE DU
SUD-EST

Rapport de stage

Étudiant
Duc Trong HOANG

Tuteur de stage
Duc Thanh NGO

Table des matières

Résumé	2
Liste des acronymes	3
1 Introduction	4
2 Matériel et Méthodologie	6
2.1 Domaine de l'étude et Données	6
2.1.1 Domaine d'Étude	6
2.1.2 Les données d'observation et les modèles	8
2.2 Méthode d'évaluation d'incertitudes des données d'observation	11
2.2.1 Introduction à l'Étude des Incertitudes des Observations	11
2.2.2 Sélection des Ensembles de Données d'Observation	11
2.2.3 Métriques Basées sur la Performance	11
2.2.4 Approche de Calcul	12
2.2.5 Analyse Régionale et Globale	12
2.3 Méthodes de correction de biais	13
2.3.1 Empirical Quantile Mapping (EQM) : Intérêt et Description Détaillée	13
2.3.2 Linear Scaling (SCL) : Intérêt et Description Détaillée	14
2.3.3 Correction de Biais par Mise à l'Échelle de l'Intensité Locale (LOCI)	15
3 Résultats	17
3.1 Comparaison des Modèles Climatiques avec les Données Observées	17
3.2 Analyse des Incertitudes dans les Données d'Observation	19
3.3 Évaluation des Biais Corrigés	22
4 Discussion	28
5 Conclusion	29
Bibliographie	30

Résumé

Cette étude a pour objectif d'évaluer et d'analyser les performances ainsi que les valeurs ajoutées des modèles climatiques CMIP6 réduits à l'échelle régionale (downscaled models) sur l'Asie du Sud-Est.

Nos recherches se concentrent sur trois principaux objectifs : tout d'abord, nous comparons la distribution spatiale et les séries temporelles des données CMIP6 (CNRM, MIROC et NorESM) réduites à l'échelle régionale sur la période historique 1981-2015 avec divers jeux de données d'observation. Cette comparaison vise à évaluer les performances et la fiabilité des simulations, tout en mettant en évidence la valeur ajoutée des produits réduits par rapport aux modèles climatiques mondiaux (GCM). Ensuite, nous analysons la cohérence de différents jeux de données d'observation griddées de précipitations, incluant APHRODITE, CRU, GPCC et CMAP. Cette analyse permet d'identifier les régions présentant des divergences significatives, essentielles pour une validation précise des modèles. Enfin, nous appliquons des méthodes de correction de biais aux sorties des modèles réduits, reconnaissant que les modèles climatiques présentent souvent des biais systématiques par rapport aux observations. Cette étape est cruciale pour améliorer la fiabilité des projections climatiques futures pour l'Asie du Sud-Est.

Dans l'ensemble, cette recherche fournit une évaluation complète des incertitudes associées aux jeux de données d'observation et de l'efficacité des modèles CMIP6 réduits à l'échelle régionale, contribuant ainsi à des projections climatiques plus précises pour la région.

MOTS-CLÉS : Asie du Sud-Est · Réduction d'échelle · Incertitudes · Précipitations · Validation des simulations · Correction de biais

Liste des acronymes

Liste des acronymes

APHRODITE	: Asian Precipitation - Highly-Resolved Observational Data Integration Towards Evaluation
CC	: Correlation Coefficient (ou coefficient de corrélation)
CMIP6	: Coupled Model Intercomparison Project Phase 6
CNRM-ESM2	: Centre National de Recherches Météorologiques - Earth System Model version 2
CORDEX	: Coordinated Regional Downscaling Experiment
CRU	: Climatic Research Unit
DJF	: Décembre Janvier Février
GCMs	: Global Climate Models (ou Modèles Climatiques Mondiaux)
GPCC	: Global Precipitation Climatology Centre
JJA	: Juin Juillet Août
LOCI	: Local Intensity Scaling
MB	: Mean Bias (ou biais moyen)
MIROC-ES2L	: Model for Interdisciplinary Research on Climate Earth System 2L
NorESM2	: Norwegian Earth System Model version 2
RegCMs ou RCMs	Regional Climate Models (ou Modèles Climatiques Régionaux)
REMODSAT lab	: Laboratory for Remote sEnsing and MOdelling of Surface and ATMosphere
SEA	: South-East Asia (ou Asie du Sud-Est)

1 Introduction

La région de l'Asie du Sud-Est (SEA) est une zone géographiquement et climatiquement complexe, s'étendant sur les deux hémisphères, Nord et Sud, et abritant environ 8,54 % de la population mondiale (Nations Unies, 2021). Cette région se caractérise par une topographie variée, comprenant la péninsule indochinoise et un vaste archipel d'îles, qui joue un rôle crucial dans les interactions climatiques locales. Le climat tropical de cette région est influencé par des phénomènes climatiques majeurs tels que les moussons et les cyclones tropicaux, qui ont un impact significatif sur les conditions de vie et les infrastructures socio-économiques. Les événements climatiques extrêmes, tels que les précipitations intenses, les vagues de chaleur, et les inondations, sont des défis constants pour les populations de la région, exacerbés par le changement climatique global.

La modélisation climatique pour l'Asie du Sud-Est présente de nombreux défis en raison de la diversité topographique et climatique de la région. Les modèles globaux de circulation générale (GCM), tels que ceux utilisés dans le cadre du Coupled Model Inter-comparison Project Phase 6 (CMIP6), offrent une représentation globale du climat, mais manquent souvent de la résolution spatiale nécessaire pour capturer les variations locales et les microclimats spécifiques à des régions complexes comme l'Asie du Sud-Est. Par conséquent, ces modèles globaux peuvent ne pas être suffisants pour fournir des projections climatiques précises à l'échelle régionale, ce qui soulève des préoccupations concernant leur capacité à informer efficacement les stratégies d'adaptation et d'atténuation au changement climatique.

Face à ces limitations, la réduction d'échelle (downscaling) apparaît comme une solution prometteuse. Le downscaling permet d'améliorer la résolution des modèles climatiques en prenant en compte les caractéristiques locales, telles que la topographie et l'influence océanique, pour produire des projections plus précises et adaptées aux besoins régionaux. Le projet Southeast Asia Regional Climate Downscaling (SEACLID), en collaboration avec le Coordinated Regional Climate Downscaling Experiment (CORDEX), vise à répondre à ce besoin en développant des simulations climatiques à haute résolution pour la région de l'Asie du Sud-Est.

Le projet CORDEX-SEA, qui s'inscrit dans le cadre de l'initiative plus large du CORDEX, utilise des modèles climatiques régionaux (RegCMs) pour simuler des scénarios climatiques futurs à une résolution de $0,25^\circ$, bien plus fine que celle des GCMs traditionnels, qui varient entre $0,5^\circ$ et $2,5^\circ$. Le modèle utilisé, RegCM4.9, permet de prendre en compte les spécificités géographiques de la région, telles que les chaînes de montagnes, les côtes et les systèmes de mousson, pour améliorer la précision des simulations climatiques.

Les simulations issues du projet CORDEX-SEA sont particulièrement importantes car elles offrent une meilleure compréhension des impacts du changement climatique sur l'Asie

du Sud-Est. Ces simulations incluent divers scénarios de forçage, ou SSP (Shared Socio-economic Pathways), qui permettent d'explorer différentes trajectoires socio-économiques et leurs impacts sur le climat régional. Les résultats de ces simulations sont essentiels pour les scientifiques, les décideurs et les acteurs de la société civile, qui s'appuient sur ces projections pour élaborer des stratégies d'adaptation et d'atténuation, ainsi que pour planifier des réponses aux catastrophes naturelles et développer des politiques durables de gestion des ressources.

Cependant, malgré les avancées significatives apportées par le downscaling, des incertitudes subsistent. Ces incertitudes sont souvent liées aux biais systémiques inhérents aux modèles climatiques, même après réduction d'échelle. Pour améliorer la fiabilité des projections, il est crucial de comparer les sorties des modèles avec des jeux de données d'observation fiables, et de corriger les biais identifiés. Les jeux de données d'observation griddées, tels qu'APHRODITE, CRU, GPCC et CMAP, jouent un rôle central dans cette évaluation, mais ils présentent eux-mêmes des variations qui peuvent influencer l'évaluation des modèles.

Dans ce contexte, cette étude se propose d'évaluer les incertitudes associées à ces jeux de données d'observation, d'analyser la performance des simulations CMIP6 réduites à l'échelle régionale, et d'explorer les méthodes de correction de biais pour améliorer la qualité des projections climatiques futures pour l'Asie du Sud-Est. Le travail entrepris dans cette étude contribue à une meilleure compréhension des défis climatiques spécifiques à cette région et fournit des outils essentiels pour la planification de l'adaptation au changement climatique.

2 Matériel et Méthodologie

2.1 Domaine de l'étude et Données

2.1.1 Domaine d'Étude

L'étude se concentre sur la région de l'Asie du Sud-Est, définie par les coordonnées géographiques suivantes :

- Longitude minimale : 86.4572525024414°
- Longitude maximale : 149.32972717285156°
- Latitude minimale : -17.338830947875977°
- Latitude maximale : 31.89867401123047°

Cette région englobe une grande variété de climats, allant des zones équatoriales humides aux zones subtropicales sèches, avec des influences monsooniennes marquées et une variabilité interannuelle importante.

Pour une analyse plus fine, la région a été divisée en sous-régions spécifiques, comme indiqué dans le tableau ci-dessous. Ces sous-régions ont été définies en tenant compte des études climatiques et des caractéristiques géographiques particulières.

Sous-Région	Longitude min	Longitude max	Latitude min	Latitude max
R1	116.30	122.70	4.90	19.80
R2	122.70	126.85	4.90	14.50
R3	114.00	119.30	1.20	7.30
R4	107.35	114.00	1.20	4.80
R5	108.25	118.50	-5.90	1.20
R6	118.50	126.95	-5.90	2.60
R7	126.95	135.00	-5.90	2.60
R8	135.00	141.10	-5.90	2.60
R9	136.50	141.10	-9.50	-5.90
R10	115.70	136.50	-11.00	-5.90
R11	104.90	115.70	-11.00	-5.90
R12	98.00	108.25	-5.90	0.10
R13	101.74	105.10	0.10	6.80
R14	94.50	101.74	0.10	6.80
R15	97.40	101.40	6.80	15.40
R16	101.40	104.80	8.55	15.40
R17	104.80	109.75	8.55	15.40
R18	104.00	108.55	15.40	24.00
R19	98.50	104.00	15.40	24.00
R20	92.00	98.50	15.40	29.00

TABLE 1 – Coordonnées des sous-régions définies pour l'analyse.

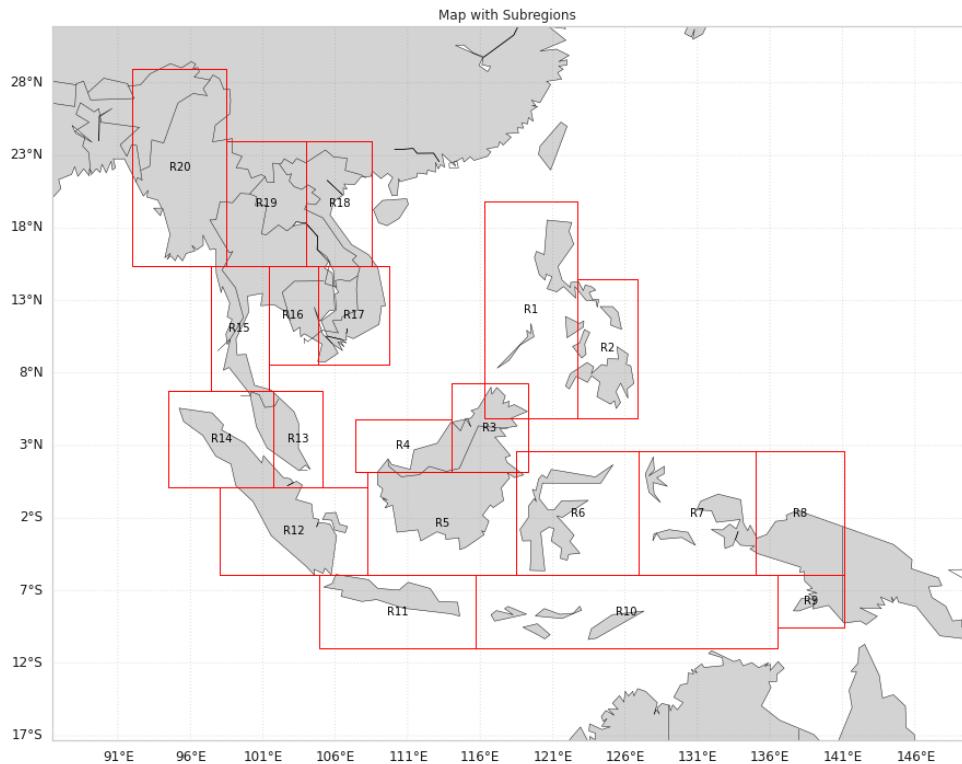


FIGURE 1 – Domaine d'étude

- **Région R1 à R4** : Ces sous-régions couvrent les parties nord et centrale de l'Indonésie. Elles présentent une variabilité élevée des précipitations avec une influence significative des saisons des moussons. Les données d'observation pour ces zones sont souvent limitées en raison des défis géographiques et logistiques, ce qui peut affecter la qualité des observations.
- **Région R5 à R8** : Situées dans les parties orientales de l'Indonésie et la région côtière de Papouasie-Nouvelle-Guinée, ces zones sont caractérisées par des précipitations abondantes et une forte variabilité saisonnière. Les observations sont généralement fiables, mais peuvent souffrir d'un manque de densité de stations.
- **Région R9 à R11** : Ces sous-régions couvrent des parties de Bornéo, Malaisie et Singapour. Les précipitations sont influencées par les systèmes monsooniques, avec des saisons sèches distinctes. Les données sont généralement disponibles mais varient en qualité, surtout dans les zones plus éloignées.
- **Région R12 à R14** : Incluant les Philippines et le sud de la Chine, ces zones présentent une diversité de régimes de précipitations allant des saisons sèches aux périodes de mousson intenses. Les données d'observation sont assez complètes, mais peuvent varier en précision selon les régions.
- **Région R15 à R17** : Ces sous-régions incluent le Myanmar et le nord de la Thaïlande, avec des précipitations influencées par la mousson d'été et les activités cycloniques. Les données sont généralement bonnes, mais peuvent être limitées

dans certaines zones reculées.

- **Région R18 à R20** : Couvrant le Vietnam et le sud de la Chine, ces zones montrent une variabilité importante des précipitations avec des pics saisonniers marqués. Les données d'observation sont généralement fiables, mais la couverture peut être inégale dans certaines parties.

Ces sous-régions ont été choisies pour leur diversité climatique et géographique, ce qui permet une évaluation approfondie des modèles climatiques et des données d'observation. La sélection de ces zones vise également à surmonter les défis liés à la qualité et à la couverture des données, offrant ainsi une analyse plus représentative des caractéristiques climatiques de l'Asie du Sud-Est.

2.1.2 Les données d'observation et les modèles

Dans cette étude, quatre produits d'observation ont été pris en compte pour évaluer les performances des modèles climatiques et les incertitudes associées :

1. Asian Precipitation-Highly Resolved Observational Data Integration Towards Evaluation of Water Resources (APHRODITE) Il s'agit d'un ensemble de données terrestres créé principalement à partir d'un réseau d'observations de pluviomètres. Les données sont disponibles avec une résolution de $0,25^\circ \times 0,25^\circ$ (environ 25 km \times 25 km). APHRODITE est réputé pour sa haute résolution et sa couverture étendue de la région asiatique.

2. Climatic Research Unit (CRU) Ce produit est basé sur des stations météorologiques terrestres et inclut les températures de l'air en surface ainsi que les précipitations (Mitchell & Jones 2005). La résolution est de $0,5^\circ \times 0,5^\circ$ (environ 50 km \times 50 km). CRU est souvent utilisé pour ses longues séries temporelles, bien que sa couverture puisse être limitée dans certaines régions.

3. Global Precipitation Climatology Centre (GPCC) Ce produit fournit des précipitations mensuelles en grille dérivées de données de stations contrôlées (Schneider et al. 2011). Sa résolution est de $0,5^\circ \times 0,5^\circ$ (environ 50 km \times 50 km). GPCC est largement utilisé pour les analyses de précipitations globales.

4. Climate Prediction Center Merged Analysis of Precipitation (CMAP) Ce produit combine des données de précipitations issues de satellites et de stations terrestres, couvrant à la fois les terres et les océans (Xie & Arkin 1997). La résolution est de $2,5^\circ \times 2,5^\circ$ (environ 250 km \times 250 km). CMAP présente une résolution temporelle et spatiale plus grossière comparée aux autres produits, mais offre une couverture globale.

Tous les champs observés et simulés ont été interpolés bilinéairement sur des grilles identiques de $0,25^\circ \times 0,25^\circ$ pour faciliter l'analyse quantitative.

Qualité des Données La qualité des ensembles de données d'observation des précipitations dépend largement de la qualité des données sources utilisées pour construire ces produits. Par exemple, CRU est connu pour avoir une couverture de données très pauvre au début du 20ème siècle, tandis que CMAP, bien qu'il produise des estimations précises des précipitations, peut présenter des biais d'échantillonnage dans certaines régions. Plusieurs études de comparaison entre ces ensembles de données d'observation montrent des divergences importantes. APHRODITE estime généralement moins de précipitations que GPCC en raison des différences dans les contrôles de qualité et les méthodes d'interpolation utilisées. D'autre part, le climat moyen de CMAP présente des similarités avec celui d'APHRODITE et montre une meilleure correspondance avec les précipitations tropicales par rapport à GPCC. Il est donc crucial de comprendre les caractéristiques et les incertitudes des produits d'observation choisis afin d'éviter des conclusions erronées concernant la performance des modèles climatiques.

Modèles Climatiques Downscalés Trois modèles climatiques downscalés ont été utilisés dans cette étude, chacun provenant de l'initiative Reg-CORDEX CMIP6, qui vise à fournir des projections climatiques régionales à haute résolution. Ces modèles — **CNRM-ESM2-1**, **MIROC-ES2L**, et **NorESM2-MM** — font partie de l'expérience Coordinated Regional Climate Downscaling Experiment (CORDEX) et ont été spécifiquement downscalés pour la région de l'Asie du Sud-Est, offrant une meilleure résolution spatiale et des projections climatiques plus détaillées.

1. CNRM-ESM2-1 Développé par le Centre National de Recherches Météorologiques (CNRM) en France, CNRM-ESM2-1 est un modèle climatique mondial (GCM) largement utilisé dans le cadre de l'ensemble CMIP6. Il a été downscalé pour l'Asie du Sud-Est à l'aide d'un modèle climatique régional (RCM) dans le cadre de l'initiative CORDEX. La version downscalée offre une résolution spatiale plus élevée par rapport au GCM d'origine, permettant une représentation plus précise des caractéristiques climatiques régionales telles que les systèmes de mousson, les régimes de précipitations et les variations de température. Le modèle CNRM inclut des paramétrisations physiques avancées et est fréquemment utilisé pour les études d'impact climatique en raison de sa performance robuste dans la simulation des conditions climatiques historiques.

2. MIROC-ES2L Développé par l'Agence japonaise pour les sciences maritimes et terrestres (JAMSTEC), l'Institut de recherche sur l'atmosphère et l'océan (AORI) de l'Université de Tokyo, et l'Institut national pour les études environnementales (NIES),

MIROC-ES2L est un autre contributeur clé au CMIP6. Ce modèle a été downscalé pour la région de l'Asie du Sud-Est dans le cadre de l'effort CORDEX, fournissant des détails spatiaux fins adaptés aux évaluations climatiques régionales. MIROC-ES2L est connu pour son traitement sophistiqué des processus atmosphériques et océaniques, y compris les dynamiques des moussons et de l'oscillation australe El Niño (ENSO), ce qui le rend particulièrement pertinent pour les études axées sur l'Asie du Sud-Est. Le jeu de données downscalé de MIROC-ES2L améliore la compréhension des impacts climatiques locaux, notamment en ce qui concerne les extrêmes de précipitations et de température.

3. NorESM2-MM Développé par un consortium d'institutions de recherche norvégiennes, y compris le Meteorological Institute of Norway (MetNorway), l'Université de Bergen et le Norwegian Institute for Air Research (NILU), NorESM2-MM est un modèle de système terrestre entièrement couplé qui intègre des représentations avancées des processus océaniques, atmosphériques et de surface terrestre. Pour l'Asie du Sud-Est, ce modèle a été downscalé à travers l'initiative CORDEX pour fournir des projections climatiques à haute résolution. NorESM2-MM est particulièrement reconnu pour sa représentation détaillée des interactions aérosols-nuages et des rétroactions du cycle du carbone, qui sont cruciales pour comprendre la variabilité et le changement climatique dans la région. La version downscalée de NorESM2-MM permet une analyse plus précise des tendances climatiques régionales, y compris les changements dans les régimes de mousson et les événements météorologiques extrêmes.

Résolution et Période d'Étude Les modèles downscalés utilisés dans cette étude ont tous une résolution horizontale de $0,25^\circ \times 0,25^\circ$ (environ 25 km \times 25 km). Cette résolution plus fine est essentielle pour capturer la topographie complexe et les caractéristiques côtières de l'Asie du Sud-Est, souvent manquées dans les modèles globaux plus grossiers. La période d'étude s'étend de **1981 à 2015**, couvrant 35 ans de données climatiques, ce qui permet une analyse complète des tendances climatiques historiques et de la variabilité dans la région.

2.2 Méthode d'évaluation d'incertitudes des données d'observation

2.2.1 Introduction à l'Étude des Incertitudes des Observations

L'évaluation des modèles climatiques repose en grande partie sur des ensembles de données d'observation précis. Cependant, ces ensembles de données sont eux-mêmes sujets à des incertitudes dues aux variations dans les méthodes de collecte, la couverture spatiale et temporelle, ainsi que les techniques de traitement des données. L'étude des incertitudes dans ces ensembles de données est essentielle pour comprendre leur fiabilité et, par conséquent, pour valider les modèles climatiques. Cette section présente la méthodologie utilisée pour étudier les incertitudes inhérentes aux ensembles de données d'observation et pour évaluer leur impact sur la validation des modèles climatiques.

2.2.2 Sélection des Ensembles de Données d'Observation

Pour cette étude, nous avons utilisé plusieurs ensembles de données d'observation griddées, notamment APHRODITE, GPCC, CRU, et CMAP, fournissant des données de précipitations à une résolution commune de $0,25^\circ \times 0,25^\circ$. Ces ensembles de données ont été sélectionnés en raison de leur utilisation répandue dans la recherche climatique, de leur couverture régionale sur l'Asie du Sud-Est, et de leur disponibilité pour la période d'étude allant de janvier 1981 à décembre 2015. Parmi ces ensembles, les données APHRODITE (Yatagai et al., 2012) ont été choisies comme référence en raison de leur précision accrue dans la région asiatique, obtenue grâce à l'utilisation de données d'observation de pluviométrie à haute densité sur une longue période temporelle. Afin d'assurer une comparaison directe avec les sorties des modèles climatiques, chaque ensemble de données a été regridé pour garantir une cohérence de la résolution spatiale.

2.2.3 Métriques Basées sur la Performance

Afin de quantifier les incertitudes dans les ensembles de données d'observation et d'évaluer la performance des modèles climatiques, trois métriques principales ont été employées : le biais moyen spatial, la corrélation de motifs, et le ratio de variabilité inter-annuelle. Ces métriques ont été calculées pour chaque modèle climatique et ensemble de données d'observation à travers 20 sous-régions définies au sein de l'Asie du Sud-Est.

- **Biais Moyen Spatial** : Cette métrique mesure la différence systématique entre les valeurs moyennes d'une variable climatique (par exemple, les précipitations) telles que simulées par le modèle et observées dans les ensembles de données. Elle fournit une estimation de l'exactitude du modèle à reproduire les valeurs observées, en mettant en évidence toute surestimation ou sous-estimation constante par le

modèle.

$$e_{q,k,n,m,c,r} = y_{q,k,n,m,r} - o_{q,k,n,c,r}$$

$$P_{q,k,m,c,r}^S = \sum_{n=1}^N e_{q,k,n,m,c,r}$$

- **Corrélation de Motifs** : Cette métrique évalue le degré de similarité entre les motifs spatiaux des données observées et simulées. En calculant le coefficient de corrélation entre les distributions spatiales de la variable climatique à travers la région, cette métrique permet de déterminer dans quelle mesure le modèle capture la variabilité spatiale présente dans les observations.

$$P_R = \frac{\text{cov}(y_n, o_n)}{\sigma(y_n)\sigma(o_n)}, \quad n = 1, \dots, N$$

- **Ratio de Variabilité Interannuelle** : Cette métrique compare la variabilité d'une année sur l'autre de la variable climatique dans le modèle par rapport à celle observée. Elle est calculée comme le ratio de l'écart-type des données simulées par rapport aux données observées sur plusieurs années. Le ratio de variabilité interannuelle est crucial pour évaluer la capacité du modèle à reproduire les fluctuations naturelles du climat au fil du temps, ce qui est essentiel pour comprendre la gravité des événements climatiques passés et futurs.

$$P_\sigma = \frac{\sigma(y)}{\sigma(o)}$$

2.2.4 Approche de Calcul

Pour chaque sous-région, modèle, et saison, les trois métriques de performance ont été calculées en comparant les données mensuelles d'observation avec les sorties correspondantes des modèles climatiques. La moyenne temporelle a été calculée sur l'ensemble des étapes temporelles pour chaque saison, tandis que les moyennes spatiales ont été dérivées en moyennant les points de données à travers la sous-région. Ces calculs ont permis une évaluation complète des incertitudes au sein des ensembles de données d'observation et de la performance des modèles climatiques.

2.2.5 Analyse Régionale et Globale

L'analyse a été menée à la fois globalement, sur l'ensemble de la région d'étude, et localement, au sein des 20 sous-régions définies. Cette approche duale a permis de capturer à la fois les tendances larges et les divergences localisées entre les ensembles de données d'observation et les modèles climatiques. En étudiant ces incertitudes à différentes échelles,

nous avons pu obtenir une meilleure compréhension de l'étendue des valeurs qui définissent les ensembles de données d'observation et, par conséquent, de la fiabilité des modèles climatiques dans la simulation des phénomènes climatiques régionaux.

2.3 Méthodes de correction de biais

La correction statistique des biais est une pratique courante dans la modélisation des impacts climatiques visant à ajuster les données des modèles climatiques pour corriger les écarts systématiques observés entre les données historiques simulées et les observations réelles. Ces méthodes reposent sur l'utilisation de fonctions de transfert, élaborées pour aligner la distribution des données simulées avec celle des observations. Une fois ces fonctions établies, elles sont appliquées aux projections futures pour garantir une correction continue des biais dans les projections climatiques à venir.

2.3.1 Empirical Quantile Mapping (EQM) : Intérêt et Description Détailée

Intérêt de la Méthode : L'Empirical Quantile Mapping (EQM) est largement utilisé pour ajuster les simulations de modèles climatiques, particulièrement pour les précipitations et les températures. Son principal avantage est de corriger non seulement les biais moyens mais aussi les écarts dans la variabilité et la distribution des données simulées par rapport aux observations. EQM rectifie les biais non linéaires et les erreurs de fréquence des jours humides, offrant ainsi une correction plus précise que les méthodes basées sur une simple échelle linéaire. Cette méthode est efficace pour les distributions asymétriques, courantes dans les données de précipitations.

Description de la Méthode : Le processus d'EQM aligne les quantiles des distributions des données simulées avec celles des données observées. Les étapes impliquées sont :

- 1. Estimation des Fonctions de Distribution Cumulée (CDF) :** Soient $F_{obs}(P_{obs})$ la fonction de distribution cumulée empirique des observations P_{obs} , et $F_{mod}(P_{mod})$ la fonction de distribution cumulée empirique des données simulées P_{mod} .
- 2. Détermination des Quantiles :** Pour chaque quantile q , on détermine le quantile correspondant dans les données simulées $P_{mod,q}$ en utilisant F_{mod} et le quantile correspondant dans les observations $P_{obs,q}$ en utilisant F_{obs} .
- 3. Construction de la Fonction de Transfert :** La fonction de transfert T est construite pour ajuster les quantiles des données simulées afin qu'ils correspondent aux quantiles observés :

$$T(P_{mod,q}) = P_{obs,q}$$

4. **Application de la Fonction de Transfert** : Les valeurs corrigées P_{bc} pour chaque donnée simulée P_{mod} sont obtenues en appliquant la fonction de transfert :

$$P_{bc} = F_{obs}^{-1}(F_{mod}(P_{mod}))$$

Cela signifie que pour chaque valeur simulée, on trouve son quantile dans la distribution simulée, puis on utilise ce quantile pour trouver la valeur correspondante dans la distribution observée.

Formule Mathématique Générale :

$$P_{bc}(t) = F_{obs}^{-1}(F_{mod}(P_{mod}(t)))$$

où t est l'indice temporel, F_{mod} est la CDF des données simulées, et F_{obs}^{-1} est la fonction inverse de la CDF des observations.

Limites de la Méthode : Bien que l'EQM soit efficace pour corriger les biais dans les distributions, elle ne prend pas en compte les changements potentiels dans la fréquence ou l'intensité des événements extrêmes dans un climat futur. De plus, elle suppose que la relation entre les quantiles observés et simulés reste constante dans le temps, ce qui peut ne pas être vrai sous des scénarios de changement climatique extrême.

2.3.2 Linear Scaling (SCL) : Intérêt et Description Détaillée

Intérêt de la Méthode : La méthode de correction de biais par Linear Scaling (SCL) est une approche simple et largement utilisée pour ajuster les simulations de modèles climatiques. Son principal avantage est sa simplicité et sa capacité à corriger les biais moyens de manière efficace. Cette méthode est particulièrement utile pour garantir que la moyenne mensuelle ou annuelle des données corrigées soit en accord avec celle des observations. SCL est souvent employée lorsque les ajustements nécessaires sont relativement simples et que les autres moments de la distribution ne nécessitent pas d'ajustement.

Description de la Méthode : La méthode SCL applique un facteur de mise à l'échelle pour ajuster les données simulées afin que la moyenne des données corrigées corresponde à la moyenne observée. Les étapes sont :

1. **Calcul de la Moyenne Mensuelle** : Calcul des moyennes mensuelles ou annuelles des précipitations observées $\mu_{obs,m}$ et simulées $\mu_{mod,m}$ pour chaque mois ou année m .

2. **Détermination du Facteur de Mise à l'Échelle :** Le facteur de mise à l'échelle sf_m est calculé comme le ratio de la moyenne observée à la moyenne simulée :

$$sf_m = \frac{\mu_{obs,m}}{\mu_{mod,m}}$$

3. **Application du Facteur de Mise à l'Échelle :** Les valeurs des données simulées $P_{mod}(t)$ sont multipliées par le facteur de mise à l'échelle sf_m pour obtenir les données corrigées $P_{bc}(t)$:

$$P_{bc}(t) = P_{mod}(t) \times sf_m$$

Formule Mathématique Générale :

$$P_{bc}(t) = P_{mod}(t) \times \frac{\mu_{obs,m}}{\mu_{mod,m}}$$

où t est l'indice temporel, m représente le mois ou l'année, $\mu_{obs,m}$ est la moyenne observée pour le mois m , et $\mu_{mod,m}$ est la moyenne simulée pour le même mois.

Limites de la Méthode : La méthode SCL, bien que simple et efficace pour ajuster les moyennes, peut ne pas correctement ajuster la distribution intra-mensuelle, ce qui peut entraîner une distorsion des moments supérieurs de la distribution, comme la variance. De plus, elle ne corrige pas les biais liés à la fréquence ou à l'intensité des événements extrêmes.

2.3.3 Correction de Biais par Mise à l'Échelle de l'Intensité Locale (LOCI)

La méthode de correction de biais Local Intensity Scaling (LOCI) ajuste les fréquences et les intensités des jours de pluie dans les séries temporelles de précipitations des modèles climatiques. Cette approche est efficace pour traiter les modèles qui présentent un excès de jours de bruine, c'est-à-dire des jours avec de faibles précipitations. LOCI améliore les données en éliminant ces jours de bruine et en ajustant les intensités de précipitation pour mieux correspondre aux observations.

Étapes de la Méthode LOCI La méthode LOCI se déroule en trois étapes principales :

1. **Détermination du Seuil des Jours de Pluie :** Le seuil de pluie $P_{thres,m}$ pour le mois m est établi pour garantir que le nombre de jours de pluie supérieur à ce seuil correspond à la fréquence des jours de pluie observés :

$$P_{thres,m} = \text{seuil de pluie pour le mois } m$$

2. **Calcul du Facteur de Mise à l'Échelle :** Un facteur de mise à l'échelle s_m est calculé en comparant les moyennes des précipitations pour les jours de pluie dans les données observées et modélisées, mais seulement pour les jours dont les précipitations sont supérieures au seuil :

$$s_m = \frac{\mu(P_{obs,m,d} | P_{obs,m,d} > 0)}{\mu(P_{raw,m,d} | P_{raw,m,d} > P_{thres,m})}$$

3. **Application de la Correction :** Les valeurs des précipitations brutes sont corrigées en appliquant le facteur de mise à l'échelle. Les valeurs inférieures au seuil sont redéfinies comme zéro, tandis que les autres valeurs sont multipliées par le facteur de mise à l'échelle :

$$P_{cor,m,d} = \begin{cases} 0, & \text{si } P_{raw,m,d} < P_{thres,m} \\ P_{raw,m,d} \times s_m, & \text{sinon} \end{cases}$$

Formule Mathématique Générale :

$$P_{cor,m,d} = \begin{cases} 0, & \text{si } P_{raw,m,d} < P_{thres,m} \\ P_{raw,m,d} \times \frac{\mu(P_{obs,m,d} | P_{obs,m,d} > 0)}{\mu(P_{raw,m,d} | P_{raw,m,d} > P_{thres,m})}, & \text{sinon} \end{cases}$$

Limites de la Méthode : LOCI peut être limité par la capacité des seuils de précipitation à capturer des événements rares et intenses. De plus, la méthode suppose que les caractéristiques des jours de pluie corrigés peuvent être ajustées proportionnellement, ce qui peut ne pas être le cas pour tous les types de données ou toutes les régions.

3 Résultats

3.1 Comparaison des Modèles Climatiques avec les Données Observées

La comparaison climatologique mensuelle globale montre que les différents produits d'observation suivent des tendances similaires, avec une augmentation des précipitations au milieu de l'année (juin-juillet-août), où elles sont deux à trois fois plus importantes que durant les mois de début et de fin d'année.

Globalement, les trois modèles climatiques simulent des précipitations plus élevées que celles observées. Cependant, les tendances saisonnières reproduites par les modèles sont relativement correctes, avec une augmentation des précipitations jusqu'en juillet, suivie d'une diminution. Parmi les modèles étudiés, le modèle NorESM semble offrir une précision globale supérieure par rapport aux deux autres modèles.

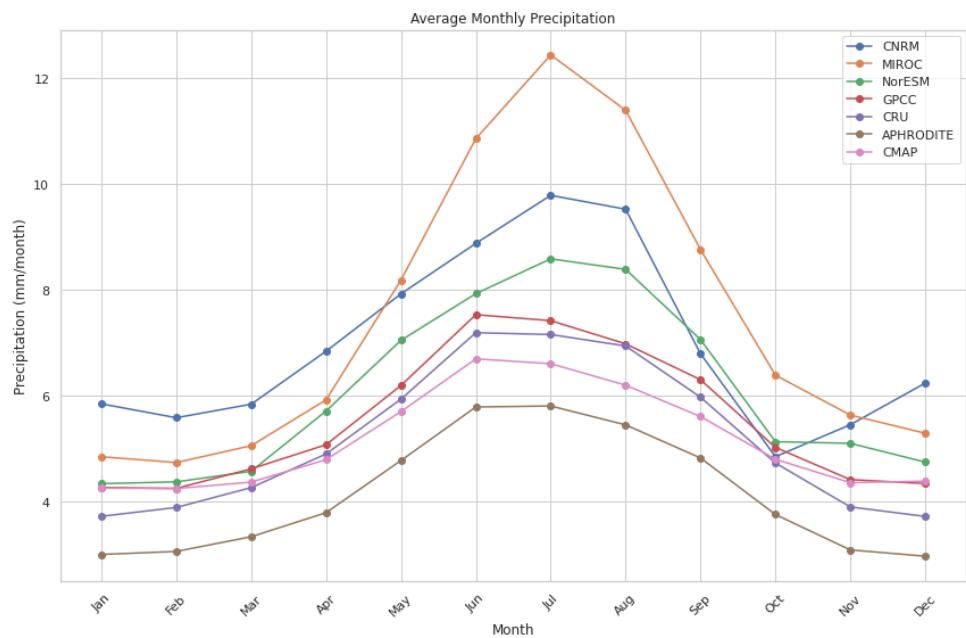


FIGURE 2 – Précipitations mensuelles moyennes globales

Les figures 3a et 3b fournissent des indicateurs de corrélation et de RMSE (Root Mean Square Error) entre chaque modèle et la médiane des observations pour chaque sous-région. Ces métriques permettent d'évaluer la performance des modèles à l'échelle régionale.

Il est constaté que les régions où les simulations sont les plus corrélées et les plus proches des observations sont les régions R16 à R20, correspondant aux pays de l'Asie du Sud-Est continentale. Ces régions montrent des performances relativement élevées en termes de concordance entre les modèles et les observations.

En revanche, les régions maritimes, qui incluent les archipels et îles, présentent davantage d'erreurs dans les simulations, avec des écarts plus prononcés par rapport aux données observées. Cela peut être attribué aux défis inhérents à la modélisation climatique dans les zones maritimes, où la complexité des interactions océan-atmosphère peut entraîner des biais plus importants.

Encore une fois, parmi les trois modèles, le modèle NorESM se distingue par sa meilleure précision dans la majorité des sous-régions, ce qui en fait le modèle le plus performant pour cette étude.

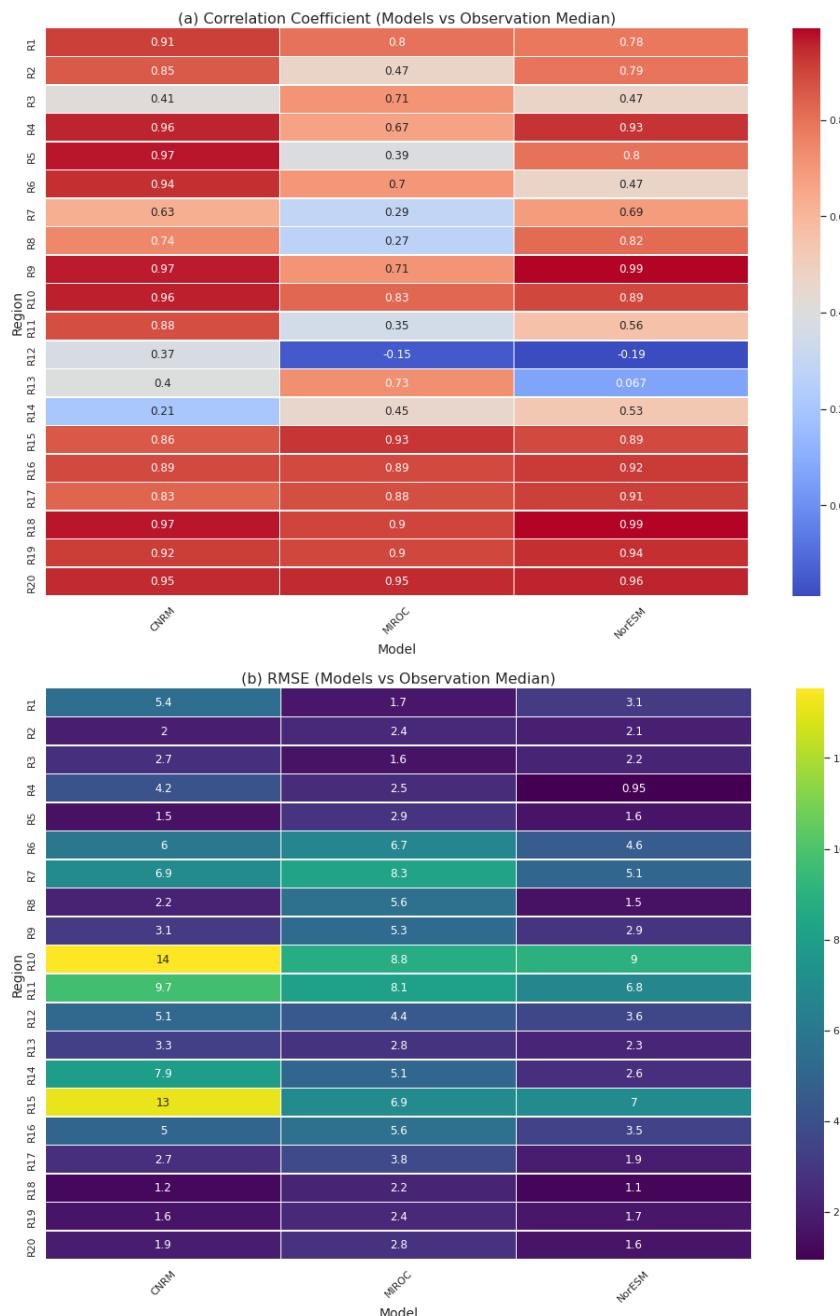


FIGURE 3 – Comparaison des modèles avec les données observées. (a) Coefficient de corrélation. (b) RMSE

3.2 Analyse des Incertitudes dans les Données d’Observation

Dans cette section, nous examinons les incertitudes présentes dans les différentes bases de données d’observation utilisées pour évaluer les modèles climatiques. L’analyse de l’erreur, telle que l’erreur quadratique moyenne (RMSE), permet de quantifier les écarts entre les diverses sources de données et d’identifier les régions où les observations sont en désaccord.

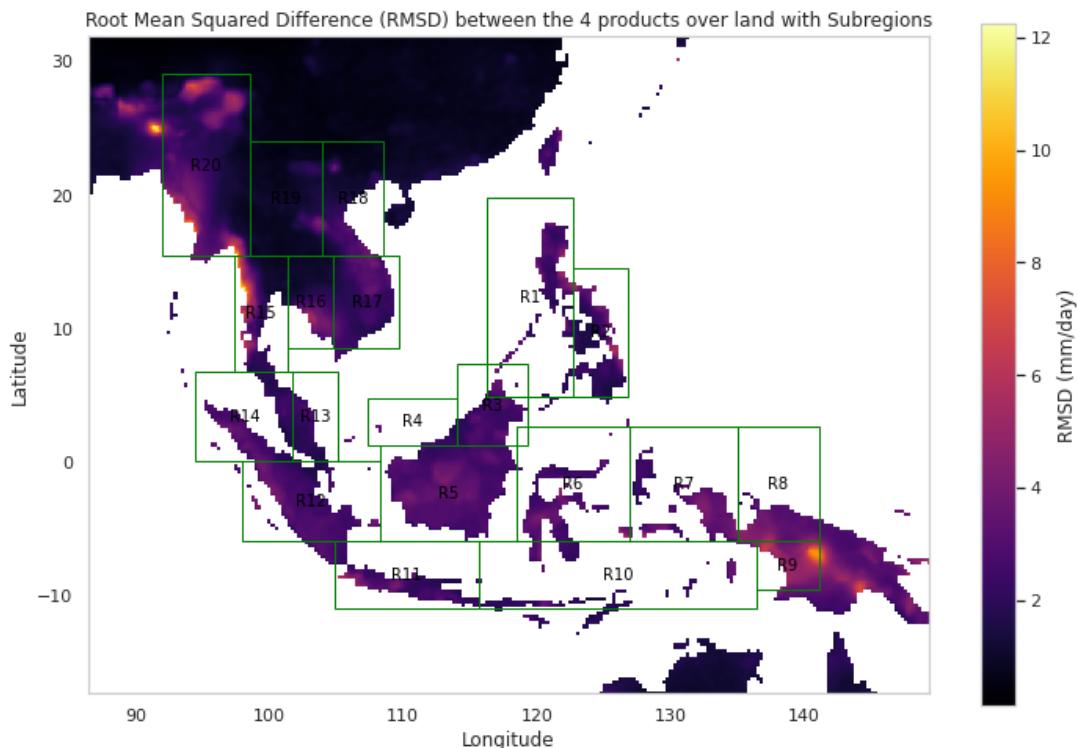


FIGURE 4 – Comparaison des RMSE entre différentes observations. Cette figure illustre les écarts entre les différentes bases de données d’observation en termes de RMSE, permettant de visualiser les incertitudes relatives.

Globalement, comme le montre la figure 4 , les différentes sources d’observation sont relativement en accord sur la majorité des régions étudiées. Toutefois, des divergences notables apparaissent dans certaines zones, notamment le long des côtes, en particulier en Birmanie (R19 et R20) et en Papouasie-Nouvelle-Guinée (R8 et R9). Ces régions se distinguent par des désaccords plus prononcés entre les différentes observations.

Les différences entre les diverses bases de données d’observation introduisent des incertitudes lors de l’évaluation des performances des modèles, ce qui influence les interprétations des résultats. Pour évaluer ces différences, nous avons comparé les distributions spatiales climatologiques annuelles et saisonnières, les corrélations de motifs, et les variabilités interannuelles entre les quatre bases de données d’observation de précipitations (ainsi que les trois modèles simulés). Nous avons utilisé les données d’Aphrodite comme

référence, en raison de sa haute résolution et de ses corrections de biais basées sur des données contrôlées de qualité.

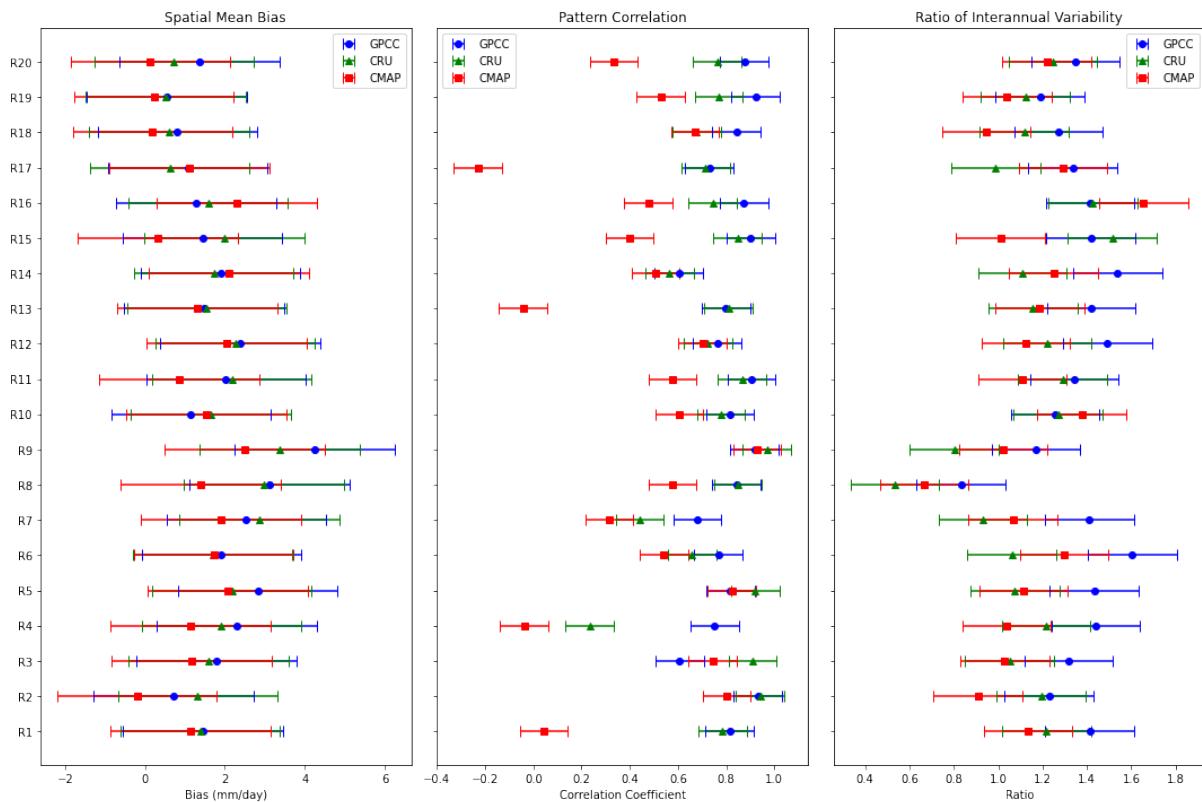


FIGURE 5 – Comparaison des trois métriques principales pour mesurer l'incertitude dans les données d'observation. Les métriques incluent le RMSE, le biais moyen, et l'erreur absolue moyenne (MAE).

Comme illustré à la figure 5, les différences inter-observations sont plus marquées pour certaines régions, avec des biais spatiaux moyens allant de 2 à 6 mm/jour. Les corrélations de motifs montrent que les données CRU et GPCC sont fortement corrélées avec le jeu de données de référence (Aphrodite), les coefficients de corrélation étant généralement autour de 0,8 pour la majorité des régions. Cependant, les données CMAP présentent des corrélations plus faibles, voire négatives dans certaines régions. La variabilité interannuelle se situe principalement entre 0,8 et 1,6, avec une dispersion plus grande des statistiques dans certaines régions.

Dans la figure 6, nous avons également inclus les données issues des trois modèles climatiques pour mieux visualiser les différences entre les observations et les simulations selon les trois métriques évaluées : le biais moyen spatial, la corrélation spatiale, et le rapport de variabilité interannuelle.

Pour le biais moyen spatial, aucune tendance particulière ne se dégage clairement. Les régions continentales de l'Asie du Sud-Est présentent des valeurs relativement proches des observations, tandis que les régions maritimes montrent des écarts plus marqués, indiquant

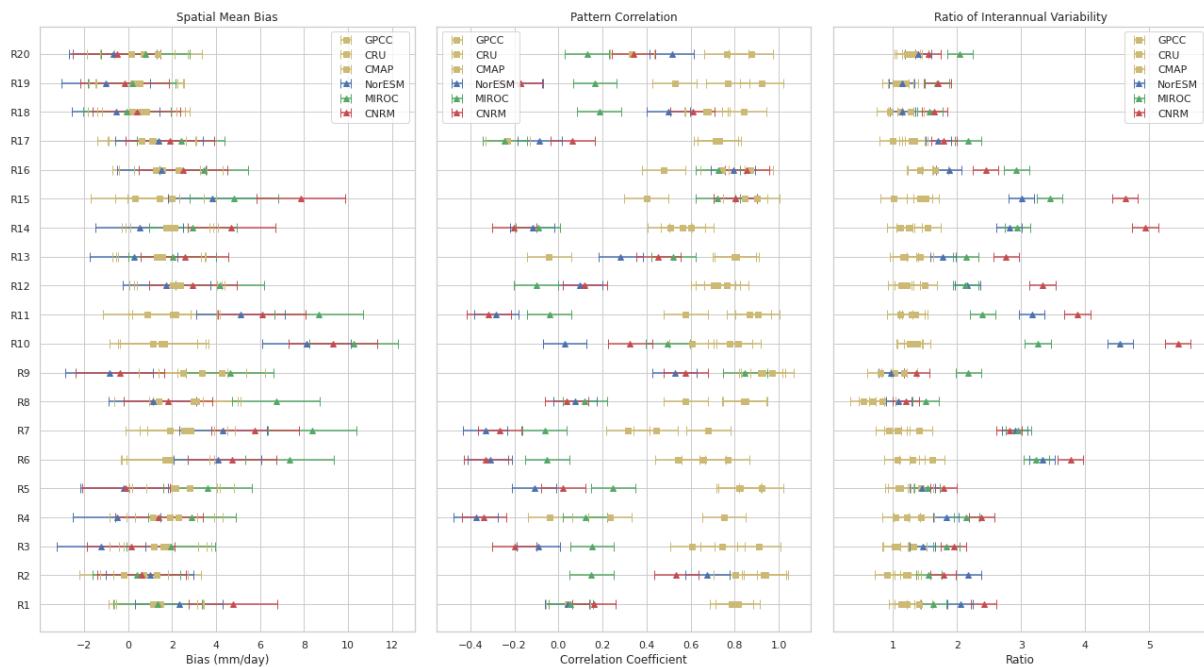


FIGURE 6 – Comparaison des trois métriques entre les observations et les modèles.

des différences significatives entre les simulations et les données observées.

Concernant la corrélation spatiale, la situation est globalement décevante. Les coefficients de corrélation sont généralement faibles et dépassent rarement 0,6, ce qui reflète une faible correspondance entre les modèles et les observations sur le plan spatial. Cette faible corrélation pourrait indiquer des difficultés des modèles à reproduire la distribution spatiale des précipitations dans certaines sous-régions.

Enfin, pour le ratio de variabilité interannuelle, les modèles présentent généralement des ratios plus élevés par rapport aux observations, notamment dans les régions allant de R6 à R15, qui correspondent principalement aux zones maritimes de l'Asie du Sud-Est. Ce biais pourrait suggérer une surestimation par les modèles de la variabilité des précipitations d'une année sur l'autre dans ces régions.

3.3 Évaluation des Biais Corrigés

Pour l'évaluation des biais corrigés, nous avons utilisé les données observées et simulées couvrant la période de 1981 à 2005 pour l'entraînement (train), afin de calculer les facteurs de correction. Ces facteurs ont ensuite été appliqués à la période de test (2005-2015) pour évaluer leur efficacité sur des données indépendantes.

Les méthodes de correction de biais jouent un rôle crucial dans l'ajustement des simulations climatiques pour qu'elles reflètent plus fidèlement les observations réelles. Elles tiennent compte des tendances climatiques, telles que les précipitations, qui sont souvent cycliques, variant de manière saisonnière et d'une année à l'autre. Le principe de séparation entre les périodes de train et de test consiste à utiliser la période de train pour calibrer les méthodes de correction, tandis que la période de test permet de vérifier l'efficacité de ces corrections sur des données nouvelles.

La méthode de Quantile Mapping ajuste les simulations en alignant la distribution statistique des données simulées sur celle des observations, garantissant ainsi que les quantiles des simulations correspondent à ceux des observations. La Scaling Correction, quant à elle, corrige les moyennes mensuelles des simulations pour qu'elles correspondent à celles des observations, en appliquant des facteurs de correction qui tiennent compte des variations saisonnières. Enfin, la méthode de Local Intensity Scaling modifie les précipitations simulées en fonction de l'intensité des jours de pluie, appliquant des corrections spécifiques aux jours humides tout en respectant la cyclicité naturelle des précipitations.

Sur la période d'entraînement, les trois méthodes de correction améliorent considérablement les biais des simulations pour toutes les régions. Les simulations corrigées sont plus proches des observations, et les tendances saisonnières en général suivent celles des observations.

La méthode de Quantile Mapping est moins performante dans les régions maritimes, en raison du manque de données et de la tendance plus monotone des précipitations. En revanche, dans les régions continentales, la méthode de Quantile Mapping est efficace et ajuste bien les simulations.

La méthode de Scaling Correction offre de très bonnes performances, bien que quelques exceptions persistent. Globalement, sur la période d'entraînement, elle est très satisfaisante.

La méthode de Local Intensity Scaling est une version améliorée de la méthode de Scaling Correction. Elle fournit une amélioration quasi-absolue de la correction, avec des simulations corrigées qui se superposent presque parfaitement aux observations.

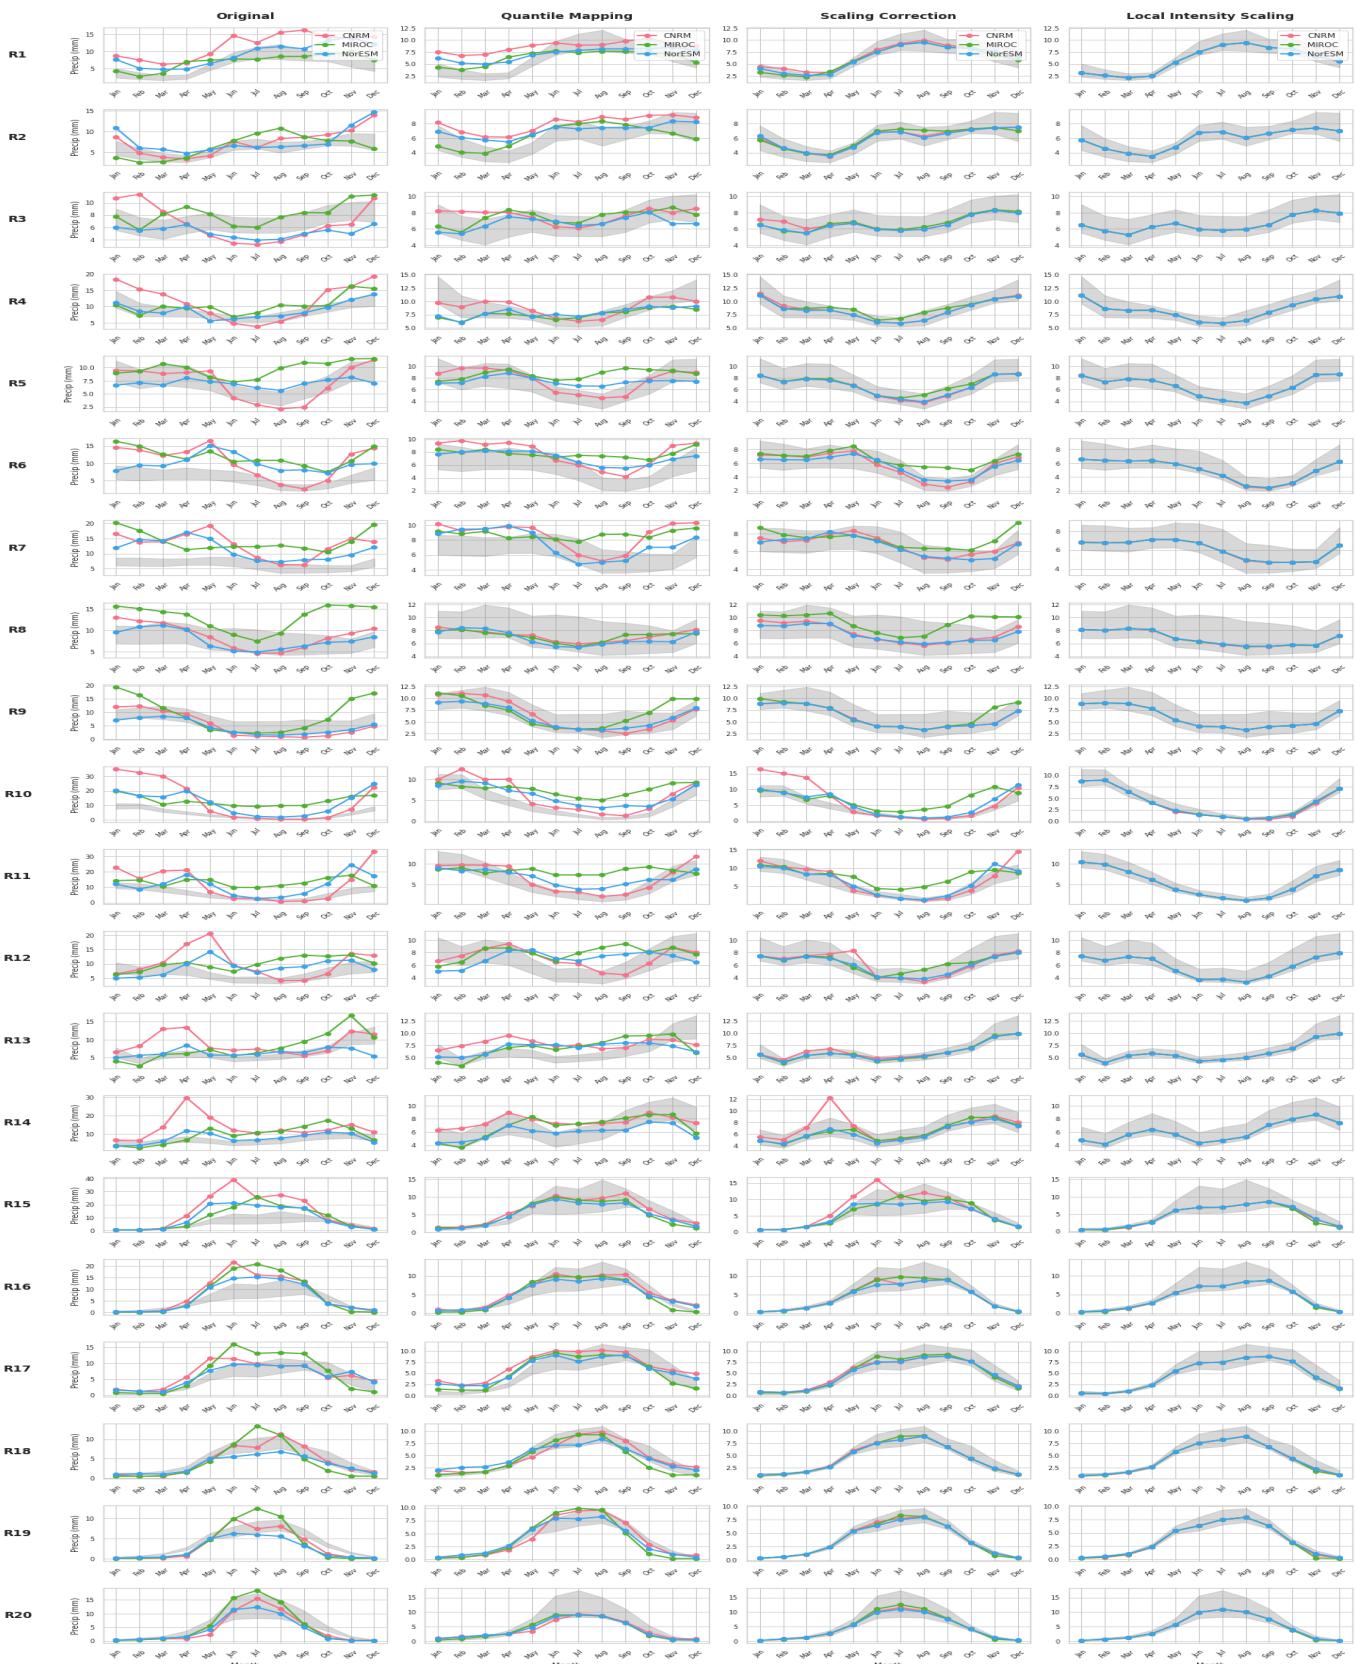


FIGURE 7 – Résultats des corrections de biais sur la période de TRAIN (1981-2005). En gris, la bande couvrant les valeurs extrêmes des observations ; les courbes sont des simulations.

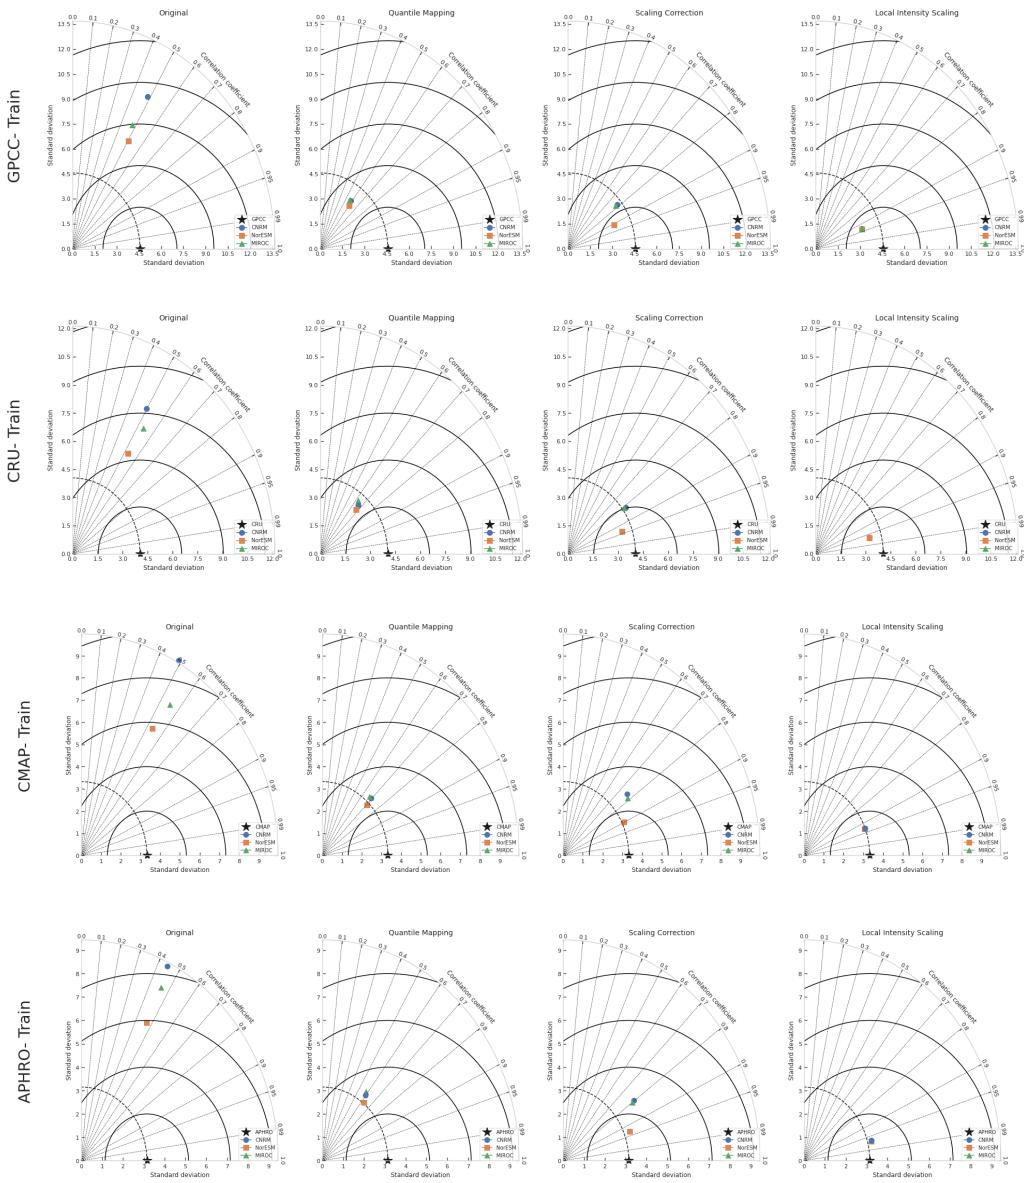


FIGURE 8 – Diagrammes de Taylor illustrant l'évaluation des performances des méthodes de correction de biais pendant la période d'entraînement.

Les diagrammes de Taylor montrent une amélioration significative des performances des méthodes de correction de biais. Les coefficients de corrélation se rapprochent de 1 après l'application des corrections, et les écarts-types des modèles corrigés se rapprochent de ceux des données d'observation. Parmi les méthodes de correction, la méthode Local Intensity Scaling (LOCI) s'avère la plus performante, avec des coefficients de corrélation augmentant de moins de 0,5 à environ 0,95. Le modèle NorESM, après correction, est le plus proche des observations, ce qui souligne son efficacité accrue avec les méthodes de correction appliquées.

Lorsque nous appliquons les coefficients de la période d'entraînement sur les données non vues de la période de test (2005-2015), nous constatons que la correction est nettement moins fluide et performante que sur la période d'entraînement. Néanmoins, de manière générale, les trois méthodes améliorent significativement les erreurs des simulations. Les régions continentales (R15-R20) sont les mieux corrigées pour les trois méthodes.

La méthode de Quantile Mapping est moins performante que les deux autres méthodes dans les régions maritimes. Les méthodes de Scaling et de Local Intensity Scaling fournissent des résultats similaires en raison de leur principe et de leur méthode similaires. Cependant, la méthode de Local Intensity Scaling améliore certains défauts de la méthode de Scaling Correction.

Les résultats taylor diagramme pour la période de test montrent des améliorations notables par rapport aux modèles originaux, bien que les performances ne soient pas aussi spectaculaires que celles observées durant la période d'entraînement. Les coefficients de corrélation et les écarts-types se sont significativement améliorés après correction. Les écarts-types des modèles corrigés sont proches de ceux des observations, tandis que les coefficients de corrélation, bien que moins élevés que durant l'entraînement, varient de 0,6 à 0,9, contre moins de 0,5 pour les modèles non corrigés. Ces résultats indiquent que les méthodes de correction de biais continuent à offrir des améliorations substantielles en période de test.

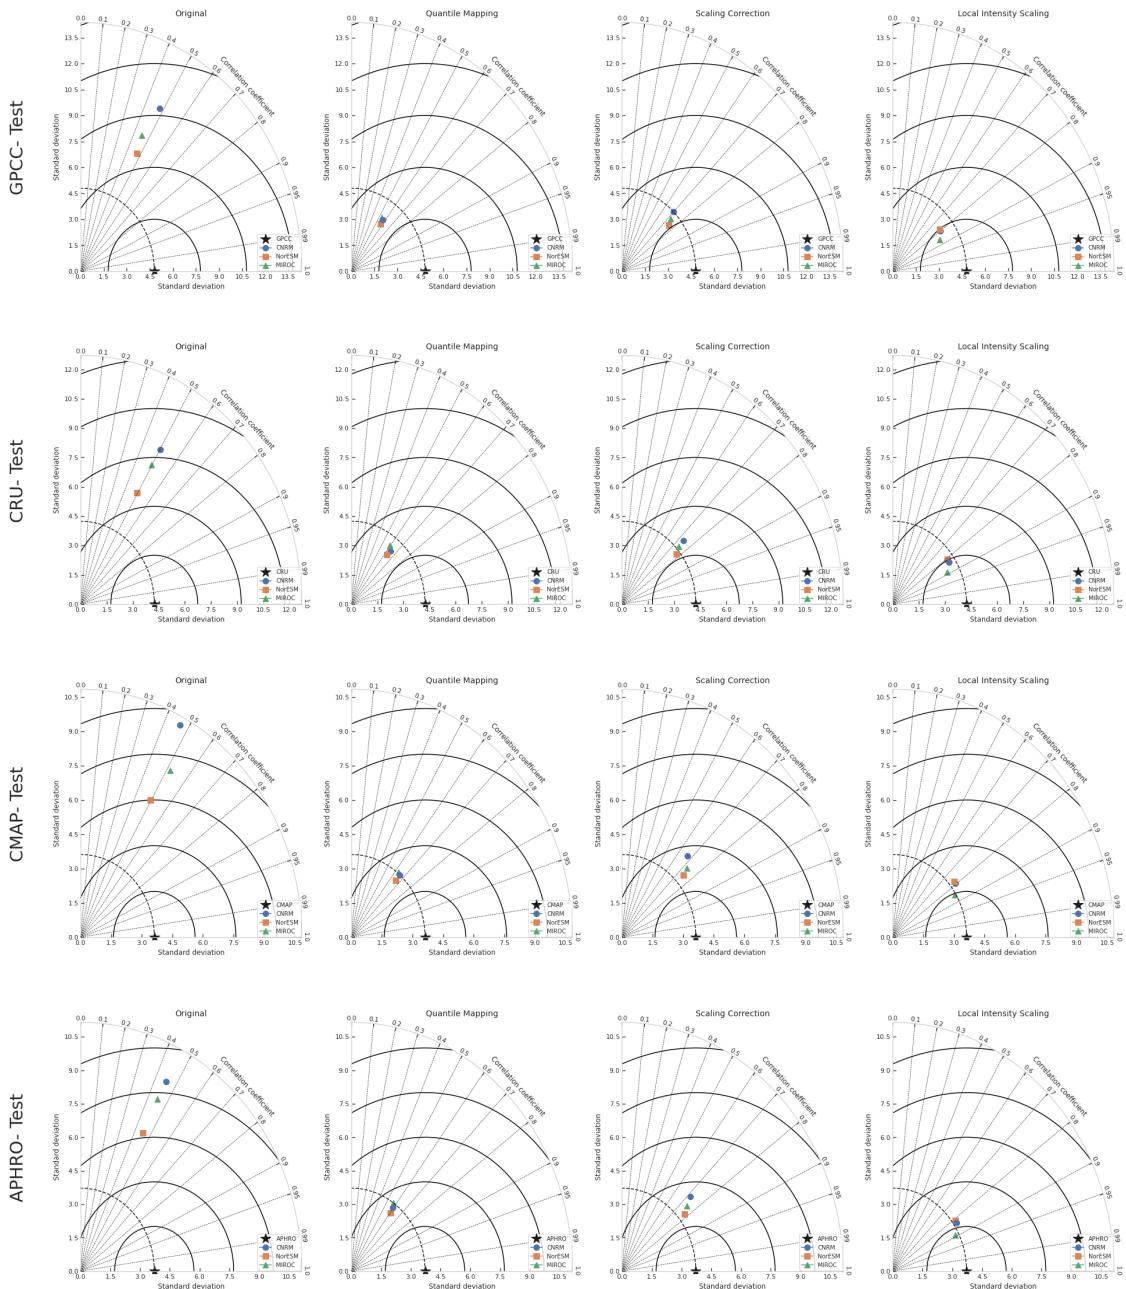


FIGURE 9 – Diagrammes de Taylor illustrant l'évaluation des performances des méthodes de correction de biais pendant la période de test.

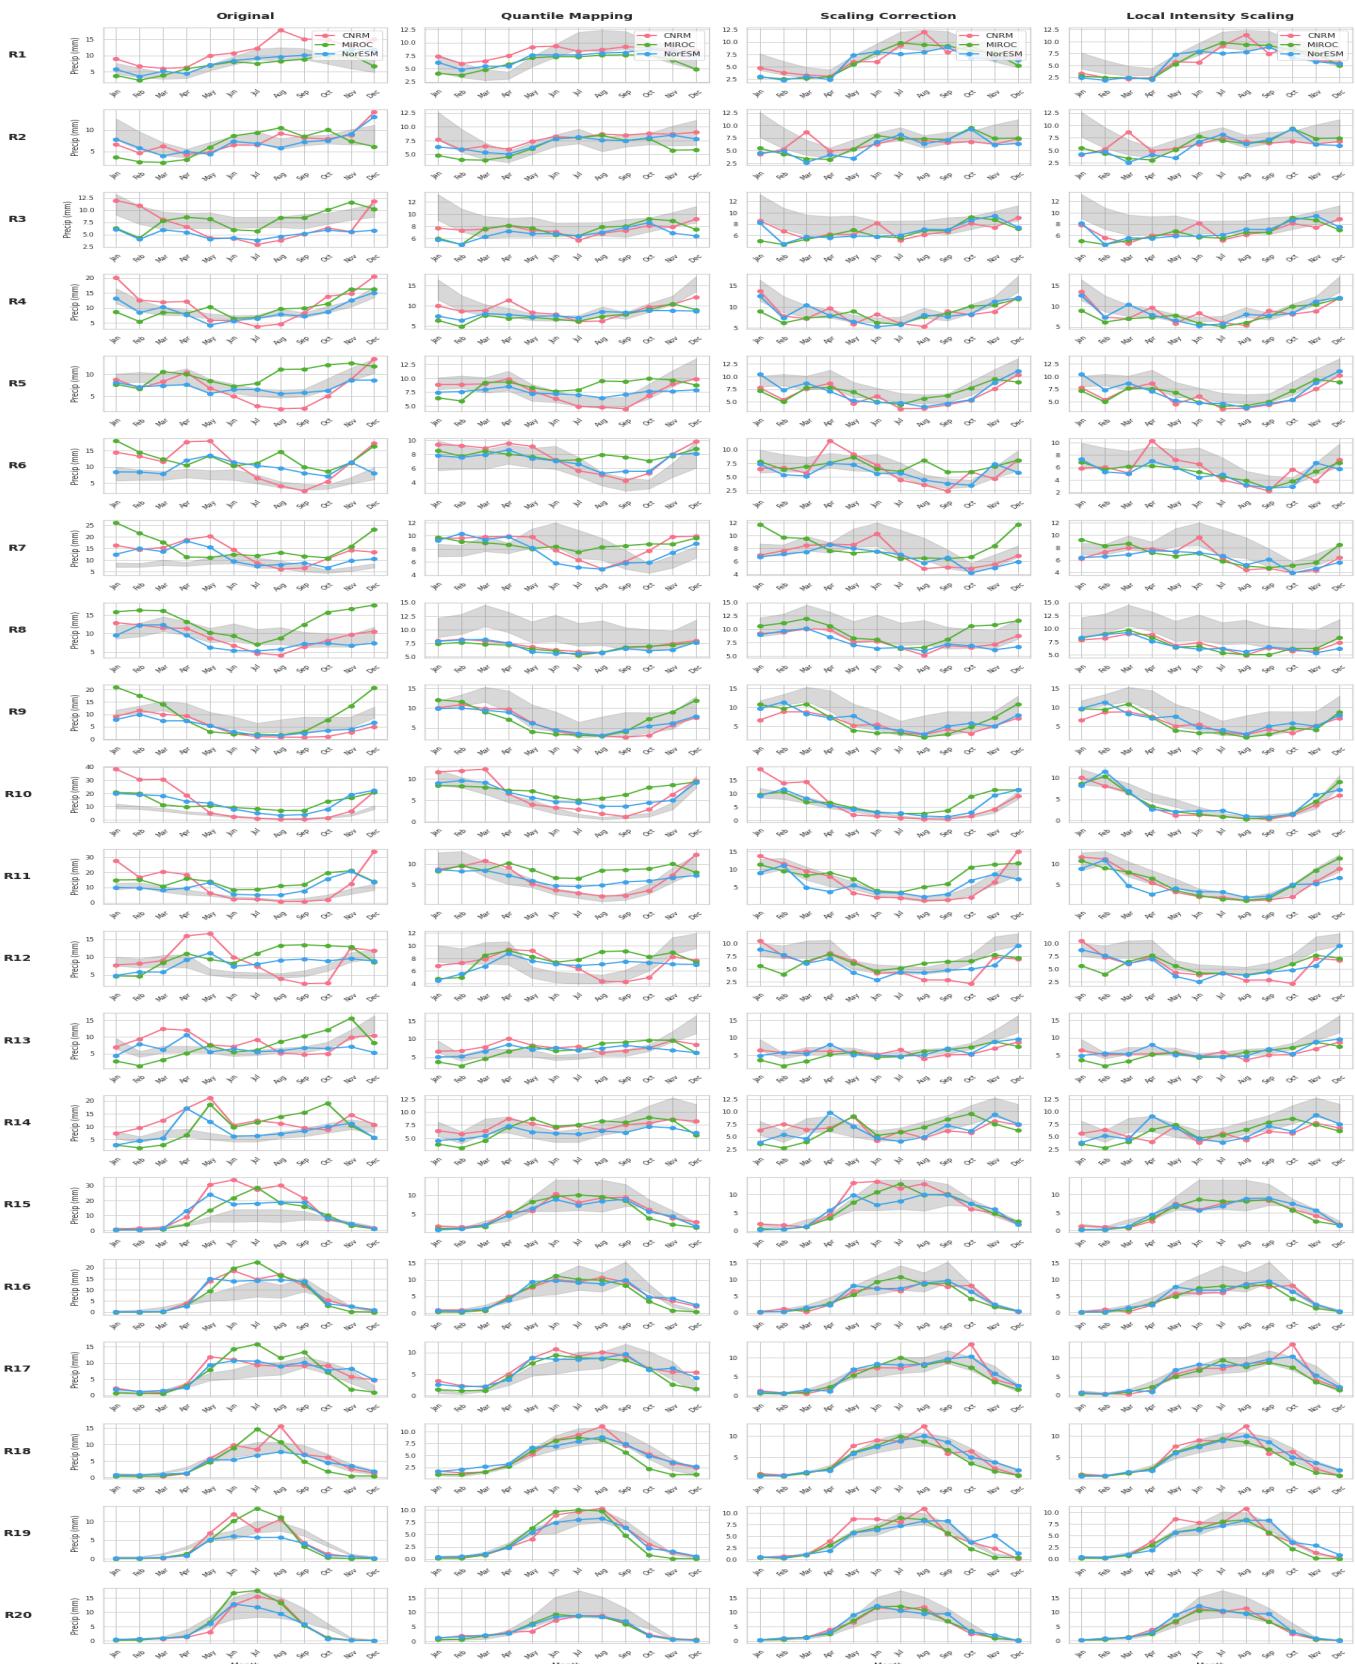


FIGURE 10 – Résultats des corrections de biais sur la période de TEST (2005-2015). En gris, la bande couvrant les valeurs extrêmes des observations ; les courbes sont des simulations.

4 Discussion

Dans le cadre de notre étude sur la quantification des performances et de la valeur ajoutée des expériences de réduction d'échelle climatique régionale sur la région de l'Asie du Sud-Est, nous avons abordé plusieurs aspects clés des données climatiques et des méthodes de correction de biais.

L'analyse a révélé que les performances des méthodes de correction de biais sont généralement satisfaisantes lorsque nous utilisons la moyenne des quatre modèles d'observation pour l'entraînement. Cependant, il est crucial de nuancer ces résultats. Les observations, malgré leur importance, contiennent des erreurs intrinsèques qui compliquent la détermination du produit d'observation le plus fiable. La décision d'exclure certains jeux de données, tels que CMAP, en faveur d'une moyenne des trois autres (APHRODITE, GPCC, et CRU) a été motivée par des incohérences observées, mais elle doit être interprétée avec prudence.

Les simulations corrigées, bien qu'elles se situent souvent dans la plage des observations, ne garantissent pas systématiquement une performance optimale. Une évaluation approfondie des tendances saisonnières des précipitations est essentielle pour juger de l'efficacité des corrections de biais. Cela permet de s'assurer que les ajustements apportés répondent correctement aux variations climatiques observées.

Un autre point important est l'inégalité dans la couverture des données entre les régions continentales et maritimes. Les régions continentales, telles que le Vietnam et la Thaïlande, bénéficient d'une meilleure couverture de données, ce qui réduit les incertitudes. En revanche, les régions maritimes, avec une couverture de données plus limitée, présentent des incertitudes plus élevées.

Enfin, bien que le régrillage des observations à la résolution d'APHRODITE facilite la comparaison et améliore la cohérence des données, il peut également entraîner une perte de précision des autres jeux de données en raison de la polarisation.

En conclusion, cette étude a permis de quantifier les performances des méthodes de correction de biais et d'évaluer la valeur ajoutée des expériences de réduction d'échelle pour la région de l'Asie du Sud-Est. Les résultats obtenus soulignent l'importance d'une approche critique et détaillée dans l'évaluation des modèles climatiques et des données d'observation, offrant ainsi des bases solides pour des recherches futures et des améliorations continues dans la modélisation climatique régionale.

5 Conclusion

Dans cette étude, nous avons évalué les performances de trois modèles climatiques downscalés de résolution $0.25^\circ \times 0.25^\circ$ du CMIP6 (Coupled Model Intercomparison Project Phase 6) : CNRM-ESM2-1, MIROC-ES2L et NorESM2-MM, sur la région de l'Asie du Sud-Est.

La comparaison climatologique globale suggère que, bien que ces modèles reproduisent correctement les tendances saisonnières des précipitations par rapport aux données d'observation, ils tendent à sur-simuler la quantité de pluie. Parmi les trois modèles, NorESM2-MM apparaît comme le plus proche des observations. Une analyse climatologique plus détaillée au niveau des sous-régions révèle que les régions continentales, qui bénéficient d'une couverture de données plus dense, sont mieux corrélées avec les simulations. En revanche, les régions maritimes, où la surface océanique est plus étendue, montrent une moindre corrélation.

Nous avons utilisé quatre produits d'observation : GPCC, CRU, CMAP et APHRODITE. Parmi ces produits, APHRODITE est particulièrement réputé pour sa résolution fine et la fiabilité de ses données dans la région de l'Asie du Sud-Est. L'étude des incertitudes des données d'observation est cruciale pour comprendre les différences entre les sources et valider les simulations. Il est essentiel de souligner que, malgré leur valeur, aucune source d'observation ne peut être considérée comme parfaitement exacte. L'analyse des incertitudes, à l'aide de métriques telles que le Spatial Mean Bias, la Pattern Correlation et le Ratio of Interannual Variability, indique que, généralement, les observations sont relativement concordantes, à l'exception de CMAP, qui présente des écarts notables dans certaines sous-régions.

Nous avons expérimenté trois méthodes de correction de biais des simulations : le Quantile Mapping, le Linear Scaling et le Local Intensity Scaling. Le principe de ces méthodes consiste à utiliser les données observées et simulées sur une période d'entraînement pour déterminer les coefficients de correction, puis à appliquer ces coefficients sur une période de test non vue. Bien que la correction appliquée sur la période de test soit généralement moins performante et plus lissée que sur la période d'entraînement, les résultats demeurent satisfaisants. Les méthodes de scaling montrent une meilleure performance que la méthode de quantile mapping dans les régions maritimes, mais sur les régions continentales, elles ne sont pas moins efficaces que les deux autres méthodes.

Enfin, il est important de nuancer les résultats en raison des choix de données d'observation, de la méthode de régrillage des données et de la résolution. Malgré ces limitations, cette étude offre un aperçu précieux de la qualité des modèles climatiques downscalés du CMIP6 et des méthodes de correction de biais.

Bibliographie

Références

- [1] Jaiswal, R., Mall, R. K., Singh, N., Lakshmi Kumar, T. V., & Niyogi, D. (2021). *Evaluation of Bias Correction Methods for Regional Climate Models : Downscaled Rainfall Analysis Over Diverse Agroclimatic Zones of India*. *Journal of Geophysical Research : Atmospheres*. Retrieved from <https://agupubs.onlinelibrary.wiley.com/doi/10.1029/2021EA001981>
- [2] Pathak, R., Dasari, H. P., Ashok, K., & Hoteit, I. (2023). *Effects of Multi-Observations Uncertainty and Models Similarity on Climate Change Projections*. *Nature Communications Earth Environment*. Retrieved from <https://www.nature.com/articles/s41612-023-00473-5>
- [3] Cui, T., Li, C., & Tian, F. (2020). *Evaluation of Temperature and Precipitation Simulations in CMIP6 Models Over the Tibetan Plateau*. *Journal of Geophysical Research : Atmospheres*. Retrieved from <https://agupubs.onlinelibrary.wiley.com/doi/10.1029/2020EA001620>
- [4] Blacutt, L., Herdies, D., Goncalves de Goncalves, L. G., Vila, D., & Andrade Flores, M. F. (2014). *Precipitation Comparison for the CFSR, MERRA, TRMM3B42, and Combined Scheme Datasets in Bolivia*. *ResearchGate*. Retrieved from https://www.researchgate.net/publication/272745534_Precipitation_comparison_for_the_CFSR_MERRA_TRMM3B42_and_Combined_Scheme_datasets_in_Bolivia
- [5] Juneng, L., Tangang, F., Chung, J., Ngai, S., Tay, T., Narisma, G., & Aldrian, E. (2016). *Sensitivity of Southeast Asia Rainfall Simulations to Cumulus and Air-Sea Flux Parameterizations in RegCM4*. *Climate Research*, 69(1), 59–77. doi :10.3354/cr01386
- [6] Maraun, D. (2017). *Bias Correcting Climate Change Simulations - A Critical Review*. *ResearchGate*. Retrieved from https://www.researchgate.net/publication/308978024_Bias_Correcting_Climate_Change_Simulations_-_A_Critical_Review
- [7] Ngai, S. T., Salimun, E., Juneng, L., Cruz, F., Tangang, F., Ngo-Duc, T., Chung, J. X., Phan-Van, T., Supari, S., Santisirisomboon, J., & Gunawan, D. (2022). *Projected Mean and Extreme Precipitation Based on Bias-Corrected Simulation Outputs of CORDEX Southeast Asia*. *Global and Planetary Change*, 211, 103811. doi :10.1016/j.gloplacha.2022.103811. Retrieved from <https://www.sciencedirect.com/science/article/pii/S2212094722000640>